Operacijski sistemi

Upravljanje z datotekami

Jurij Mihelič, FRI, Uni LJ

Vsebina

- Logična organizacija podatkov
  - datoteka, imenik itd.
  - hierarhija in naslavljanje datotek
- Datoteke
  - abstrakcija, tipi datotek
- Kodiranje datotek

Logična organizacija podatkov

- **Datoteka**
  - osnovna zaključena zbirka podatkov
    - **dolgotrajna obstojnost** (odvisna od pomnilnega medija)
    - jo lahko naslovimo oz. identificiramo preko imena
  - **vsebina** datoteke
    - podatki, ki jih datoteka hrani
  - **atributi** (meta podatki) datoteke
    - pripadajoči podatki o datoteki

- ime datoteke
- velikost datoteke
- datum in čas nastanka in spremembe datoteke
- lastnik in skupina datoteke
- dovoljenja za uporabo
- …

Logična organizacija podatkov

- **Imenik**
  - omogoča združevanje (sorodnih) datotek
    - vsebuje datoteke in druge imenike oz.
    - vsebuje seznam datotek (in pripadajočih atributov)
  - podobnost z datoteko
    - vsebino imenika OS *razume*
    - vsebina je seznam datotek

imenik, mapa, kazalo, directory, folder

Logična organizacija podatkov

- Hierarhična struktura imenikov
  - gnezdenje imenikov in datotek
    - poljubna globina gnezdenja
  - odnosi med imeniki
    - **podimenik** (sub-direcotory)
      - imenik vsebovan v danem imeniku
    - **nadimenik** (super-directory, parent directory)
      - imenik, ki vsebuje dani imenik
  - **korenski** imenik (root directory)
    - imenik, ki nima nadimenika (ni nikjer vsebovan)

Nekateri starejši sistemi nimajo poljubnega gnezdenja.

Logična organizacija podatkov

- Naslavljanje datotek
  - **pot** (path) do datoteke
    - seznam imen imenikov od ustreznega izvornega imenika do dane datoteke
  - **absolutna pot**
    - pot, ki se prične v *korenskem imeniku*
  - **relativna pot**
    - pot, ki se prične v *trenutnem delovnem imeniku*

	/ korenski imenik, ločilo v poti (Unix) \ korenski imenik, ločilo v poti (Windows) . trenutni imenik .. imenik starša trenutnega imenika ~ domači imenik uporabnika	

Datoteke

- Abstrakcija datoteke
  - datoteka je pogosto splošnejši koncept
  - različni **tipi datotek**
  - OS nekatere tipe posebej obravnava

Non-file file types

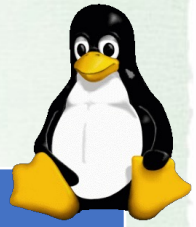

oznaka	opis	primer
-	navadna datoteka (regular file)	`/etc/passwd`
d	imenik (directory)	`/bin`
l	simbolična povezava (symbolic link)	`/usr/src/linux`
b	bločna naprava (block special device)	`/dev/sda`
c	znakovna naprava (character special device)	`/dev/tty`
p	imenovana cev (named pipe)	
s	lokalna vtičnica (local/domain socket)	

Datoteke

- **Navadna** datoteka
  - vsebina datoteke
    - poljubna interna struktura oz. format datoteke
    - OS omogoča notranje operacije (nad vsebino)
      - odpiranje, zapiranje, branje, pisanje, …
  - **vrsta (navadne) datoteke**
    - različne vrste datotek glede na vsebino
    - pogosto del imena (npr. končnica) podaja vrsto
    - veliko različnih vrst
      - odvisno od uporabniških in programskih potreb
      - npr. tekstovna datoteka, izvršljiva datoteka, slika, avdio, video, ...

Datoteke

- **Imenik**
  - datoteka posebnega tipa
    - njena vsebina je seznam imeniških vnosov
    - vsak imeniški vnos ustreza neki datoteki

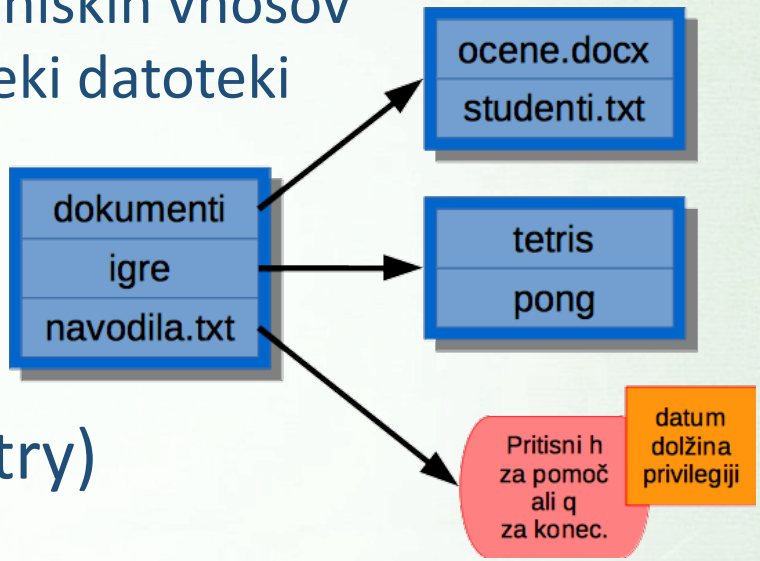

  - **imeniški vnos** (directory entry)
    - **ime** datoteke
    - **kazalci** na ostale podatke (vsebina, meta-podatki)
    - znotraj imenika ni mogoče imeti imeniških vnosov z enakim imenom

Datoteke

Trda povezava
ni nov tip datoteke.

- Trda povezava
  - dodaten imeniški vnos (za isto *datoteko*)
    - trda povezava je enakovredna imeniškemu vnosu
    - različni imeniški vnosi lahko predstavljajo isto datoteko (datoteka z več imeni)
  - ukaz: `ln` *original trda*
    - Katera je original? Kako datoteko zbrišemo?

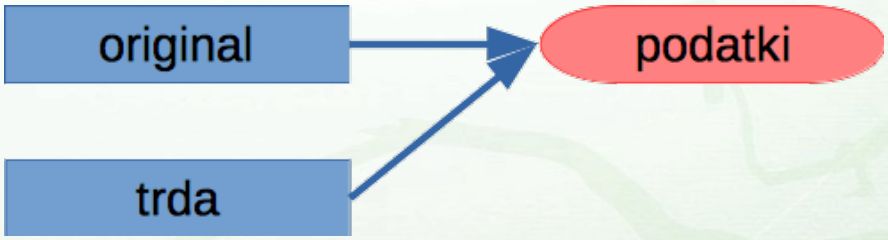

Datoteke

- **Simbolična** (mehka) **povezava**
  - datoteka posebnega tipa
  - vsebina datoteke (simbolične povezave)
    - naslov (pot do) ciljne datoteke
  - večina ukazov avtomatsko sledi povezavi
    - operira na ciljno datoteko
  - ukaz: `ln -s` *original mehka*

Datoteke

- **Bločna** in **znakovna naprava**
  - dva posebna tipa datotek
  - branje in pisanje takšne datoteke se neposredno nanaša na napravo
  - **bločna** naprava
    - dostop po blokih (npr. 4096 B)
  - **znakovna** naprava
    - dostop po znakih oz. bajtih

Datoteke

- **Cev** (pipe) in **vtičnica** (socket)
  - mehanizma za medprocesno komunikacijo
  - naslavljanje preko imen datotek
    - nadzor dostopa preko datotečnih dovoljenj
  - **imenovana cev** (named pipe), *FIFO*
    - ustvarimo z `mkfifo`
    - nudijo enak vmesnik kot datoteke
  - **lokalna vtičnica** (local socket), *Unix domain socket*
    - poseben vmesnik
    - BSD knjižnica vtičnic nudi enoten API tako za lokalne kot internetne vtičnice
      - ročica vtičnice je datotečni deskriptor

Kodiranje datotek

- Kodiranje znakov
  - preslikava *zaporedja* bajtov v znake
  - kodiranja iz sorodnih področij
    - Morsejeva koda, Braillova pisava, Baudotjeva koda
    - IBM BCD & EBCDIC
  - pomebno predvsem za **tekstovne datoteke**
    - tekst = neformatirano besedilo

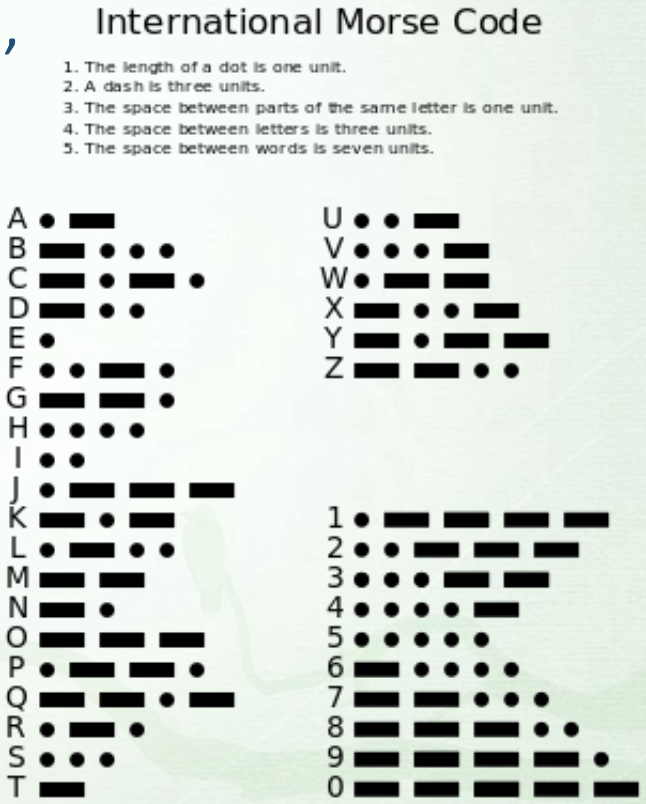

Kodiranje datotek

American Standard Code for Information Interchange

- Kodiranje ASCII
  - izhaja iz telegrafskih kodiranj
  - nastalo v 1960’
  - 7 bitno kodiranje
    - 95 vidnih znakov
    - 33 ne-vidnih, kontrolnih kod

	0	1	2	3	4	5	6	7
0	NUL	DLE	space	0	@	P	`	p
1	SOH	DC1 XON	!	1	A	Q	a	q
2	STX	DC2	"	2	B	R	b	r
3	ETX	DC3 XOFF	#	3	C	S	c	s
4	EOT	DC4	$	4	D	T	d	t
5	ENQ	NAK	%	5	E	U	e	u
6	ACK	SYN	&	6	F	V	f	v
7	BEL	ETB	'	7	G	W	g	w
8	BS	CAN	(	8	H	X	h	x
9	HT	EM	)	9	I	Y	i	y
A	LF	SUB	*	:	J	Z	j	z
B	VT	ESC	+	;	K	[	k	{
C	FF	FS	,	<	L	\	l	|
D	CR	GS	-	=	M	]	m	}
E	SO	RS	.	>	N	^	n	~
F	SI	US	/	?	O	_	o	del

Kodiranje datotek

- Izzivi internacionalizacije
  - ASCII oz. US-ASCII
    - podpora latinski abecedi in peščici simbolov
    - manjkajo znaki ne-angleških jezikov
  - standard YUSCII, 7 bitov
    - https://en.wikipedia.org/wiki/YUSCII
  - ostale razširitve ASCII, 8 bitov
    - ISO-IEC 8859-1 (Latin 1),
    - ISO-IEC 8859-2 (Latin 2),
    - Windows CP-1250,
    - ...

koda	ASCII	YUSCII
40	@	Ž
5B	[	Š
5C	\	Đ
5D	]	Ć
5E	^	Č
60	`	ž
7B	{	š
7C	|	đ
7D	}	ć
7E	~	č

Kodiranje datotek

- Standard Unicode
  - nabor UCS – universal character set
  - svetoven repertoar znakov, tudi ČŠŽčšž ☺
  - 21-bitni kodni prostor (codespace)
    - kodne točke od U+0000 do U+10FFFF
      - 1.114.112 kodnih točk
      - 2^{11} rezerviranih (od U+D800 do U+DFFF)
      - možnih torej 1.112.064 kodnih točk
    - razdeljen na 17 ravnin (plane) od 0 do 0x10
      - 0 - osnovna ravnina, …
  - kodirani znaki
    - opisuje 143.859 znakov in pokriva 154 pisav (2020)
    - prvih 256 znakov je identičnih ISO-IEC 8859-1

Kodiranje datotek

- Različna kodiranja
  - UTF – unicode transformation format
  - Kodiranje UTF-32
    - 4 bajti, začetni biti so 0
    - vsaka vrednost predstavlja natančno kodno točko s to vrednostjo
    - prostorsko neučinkovit, zelo redka uporaba
  - Kodiranje UTF-16
    - ena ali dve dvobajtni besedi
    - uporaba znotraj Windows, JVM, CLI, JavaScript, KDE, macOS
    - tudi Microsoft opušča ta način
  - Kodiranje UTF-8
    - Unixu podobni sistemi, svetovni splet

Kodiranje datotek

- Standard UTF-8
  - razširjen ASCII, se ujema v prvih 128 znakih
  - porabi od 1 do 4 bajtov/znak.
  - podpira samo-sinhronizacijo.

# bajtov	začetna kodna točka	zadnja kodna točka	bajt 1	bajt 2	bajt 3	bajt 4
1	U+0000	U+007F	0xxxxxxx			
2	U+0080	U+07FF	110xxxxx	10xxxxxx		
3	U+0800	U+FFFF	1110xxxx	10xxxxxx	10xxxxxx	
4	U+10000	U+10FFFF	11110xxx	10xxxxxx	10xxxxxx	10xxxxxx

Kodiranje datotek

- Skok v novo vrstico
  - kontrolni znaki
    - LF – naslednja vrstica
    - CR – skok na začetek vrstice
    - ipd., glej tudi WP:Newline

- CR+LF (zaradi kompatibilnosti s “tiskalniki”)
  - TENEX, DEC OS (RT-11, OS/8, RSX-11, …, TOPS-10), CP/M,
  - DOS, OS/2, Windows, Symbian, ARPANET/Internet (telnet, …)
- LF
  - Multics, Amiga, BeOS, RISC OS, Unix, Unix-like
  - macOS, Linux, FreeBSD
- CR
  - ZX Spectrum, Commodore C64/C128, Mac OS (< v.9), Oberon